Министерство образования Республики Беларусь

Учреждение образования «Брестский государственный технический университет»

Кафедра ИИТ

# ЛАБОРАТОРНАЯ РАБОТА №1

По дисциплине: «Основы машинного обучения»

Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:

Студент 3 курса

Группы АС-67

Стражевич А.С.

Проверил:

Крощенко А. А.

Брест 2026

**Цель работы:** получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

## Ход работы

## Вариант 8

**Общее задание:**

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.

2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).

3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).

4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.

5. Выполнить нормализацию или стандартизацию числовых признаков.

6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.

7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

**Задание по варианту:**

Выборка Pima Indians Diabetes. Содержит медицинские показатели женщин из племени Пима и информацию о наличии у них диабета.

Задачи:

1. Загрузите данные и выведите их статистические характеристики.

2. Проанализируйте столбцы Glucose, BloodPressure, SkinThickness. Нулевые значения в них, скорее всего, являются ошибками. Замените их медианным значением соответствующего столбца.

3. Постройте гистограммы для признаков BMI и Age.

4. Создайте матрицу корреляции только для признаков Glucose, BMI, Age и Outcome.

5. Визуализируйте распределение Outcome (наличие диабета) с помощью круговой диаграммы.

6. Примените стандартизацию ко всем признакам, кроме Outcome.

**Код программы:**

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler
```

```
#0. ЗАГРУЗКА ДАННЫХ
columns = ['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness',
           'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age',
'Outcome']

df = pd.read_csv('pima-indians-diabetes.csv', encoding='utf-8-sig',
                 skiprows=9, header=None, names=columns)

print("Размер датасета:", df.shape)
print(df.head())

#1. СТАТИСТИКА
print("\n--- ПУНКТ 1: Описательная статистика ---")
print(df.describe())

print("\nТипы данных:")
print(df.dtypes)

print("\nНули в ключевых столбцах (это пропуски):")
for col in ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin',
'BMI']:
    print(f"  {col}: {(df[col] == 0).sum()}")

#2. ЗАМЕНА НУЛЕЙ МЕДИАНОЙ
print("\n--- ПУНКТ 2: Замена нулей медианой ---")
cols_to_fix = ['Glucose', 'BloodPressure', 'SkinThickness']

for col in cols_to_fix:
    med = df.loc[df[col] != 0, col].median()
    df.loc[df[col] == 0, col] = med
    print(f"  {col}: медиана = {med:.2f}")

print("Нулей после замены:")
for col in cols_to_fix:
    print(f"  {col}: {(df[col] == 0).sum()}")

#3. ГИСТОГРАММЫ BMI и AGE
print("\n--- ПУНКТ 3: Гистограммы ---")

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].hist(df['BMI'], bins=25, color='skyblue', edgecolor='black')
axes[0].set_title('Распределение BMI')
axes[0].set_xlabel('BMI')
axes[0].set_ylabel('Частота')

axes[1].hist(df['Age'], bins=25, color='salmon', edgecolor='black')
axes[1].set_title('Распределение возраста')
axes[1].set_xlabel('Age')
axes[1].set_ylabel('Частота')

plt.tight_layout()
plt.savefig('hist_bmi_age.png', dpi=120, bbox_inches='tight')
plt.show()

#4. МАТРИЦА КОРРЕЛЯЦИИ
print("\n--- ПУНКТ 4: Матрица корреляции ---")
```

```
subset = df[['Glucose', 'BMI', 'Age', 'Outcome']]
corr = subset.corr()
print(corr.round(3))

fig, ax = plt.subplots(figsize=(7, 6))
im = ax.imshow(corr.values, cmap='coolwarm', vmin=-1, vmax=1)
ax.set_xticks(range(len(corr.columns)))
ax.set_yticks(range(len(corr.columns)))
ax.set_xticklabels(corr.columns, rotation=45, ha='right')
ax.set_yticklabels(corr.columns)

for i in range(len(corr.columns)):
    for j in range(len(corr.columns)):
        ax.text(j, i, f'{corr.values[i, j]:.2f}',
                ha='center', va='center', color='black', fontsize=11)

plt.colorbar(im, ax=ax)
ax.set_title('Матрица корреляции')
plt.tight_layout()
plt.savefig('corr_matrix.png', dpi=120, bbox_inches='tight')
plt.show()

target_corr =
corr['Outcome'].drop('Outcome').sort_values(ascending=False)
print("\nСамый сильный предиктор:", target_corr.idxmax(),
      f"(r = {target_corr.max():.3f})")
```

**#5. КРУГОВАЯ ДИАГРАММА OUTCOME**

```
print("\n--- ПУНКТ 5: Распределение Outcome ---")

counts = df['Outcome'].value_counts().sort_index()
print("Без диабета (0):", counts[0])
print("С диабетом  (1):", counts[1])

fig, ax = plt.subplots(figsize=(7, 7))
ax.pie(counts, labels=['Без диабета (0)', 'С диабетом (1)'],
       autopct='%1.1f%%', colors=['#7fcdbb', '#e34a33'],
       startangle=90, shadow=True)
ax.set_title('Распределение пациенток по наличию диабета')
plt.tight_layout()
plt.savefig('pie_outcome.png', dpi=120, bbox_inches='tight')
plt.show()
```

**#6. СТАНДАРТИЗАЦИЯ**

```
print("\n--- ПУНКТ 6: Стандартизация ---")

features = df.drop('Outcome', axis=1)
target = df['Outcome']

scaler = StandardScaler()
features_scaled = pd.DataFrame(
    scaler.fit_transform(features),
    columns=features.columns
)

print("Средние после стандартизации (должны быть ≈ 0):")
print(features_scaled.mean().round(4))
```

```
df_scaled = features_scaled.copy()
df_scaled['Outcome'] = target.values
df_scaled.to_csv('diabetes_cleaned_scaled.csv', index=False)

print("\nГотово! Файлы сохранены рядом со скриптом.")
```

**Результат программы:**

```
Размер датасета: (768, 9)
   Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin   BMI  DiabetesPedigreeFunction  Age  Outcome
0            6      148             72             35        0  33.6                     0.627   50        1
1            1       85             66             29        0  26.6                     0.351   31        0
2            8      183             64              0        0  23.3                     0.672   32        1
3            1       89             66             23       94  28.1                     0.167   21        0
4            0      137             40             35      168  43.1                     2.288   33        1

--- ПУНКТ 1: Описательная статистика ---
       Pregnancies     Glucose  BloodPressure  SkinThickness     Insulin         BMI  DiabetesPedigreeFunction         Age     Outcome
count   768.000000  768.000000     768.000000     768.000000  768.000000  768.000000                768.000000  768.000000  768.000000
mean      3.845052  120.894531      69.105469      20.536458   79.799479   31.992578                  0.471876   33.240885    0.348958
std       3.369578   31.972618      19.355807      15.952218  115.244002    7.884160                  0.331329   11.760232    0.476951
min       0.000000    0.000000       0.000000       0.000000    0.000000    0.000000                  0.078000   21.000000    0.000000
25%       1.000000   99.000000      62.000000       0.000000    0.000000   27.300000                  0.243750   24.000000    0.000000
50%       3.000000  117.000000      72.000000      23.000000   30.500000   32.000000                  0.372500   29.000000    0.000000
75%       6.000000  140.250000      80.000000      32.000000  127.250000   36.600000                  0.626250   41.000000    1.000000
max      17.000000  199.000000     122.000000      99.000000  846.000000   67.100000                  2.420000   81.000000    1.000000

Типы данных:
Pregnancies                 int64
Glucose                     int64
BloodPressure               int64
SkinThickness               int64
Insulin                     int64
BMI                       float64
DiabetesPedigreeFunction  float64
Age                         int64
Outcome                     int64
dtype: object

Нули в ключевых столбцах (это пропуски):
  Glucose: 5
  BloodPressure: 35
  SkinThickness: 227
  Insulin: 374
  BMI: 11

--- ПУНКТ 2: Замена нулей медианой ---
  Glucose: медиана = 117.00
```

```
--- ПУНКТ 2: Замена нулей медианой ---
  Glucose: медиана = 117.00
  BloodPressure: медиана = 72.00
  SkinThickness: медиана = 29.00
Нулей после замены:
  Glucose: 0
  BloodPressure: 0
  SkinThickness: 0

--- ПУНКТ 3: Гистограммы ---

--- ПУНКТ 4: Матрица корреляции ---
         Glucose    BMI    Age  Outcome
Glucose    1.000  0.235  0.267    0.493
BMI        0.235  1.000  0.036    0.293
Age        0.267  0.036  1.000    0.238
Outcome    0.493  0.293  0.238    1.000

Самый сильный предиктор: Glucose (r = 0.493)

--- ПУНКТ 5: Распределение Outcome ---
Без диабета (0): 500
С диабетом  (1): 268

--- ПУНКТ 6: Стандартизация ---
Средние после стандартизации (должны быть ≈ 0):
Pregnancies                -0.0
Glucose                     0.0
BloodPressure               0.0
SkinThickness              -0.0
Insulin                    -0.0
BMI                         0.0
DiabetesPedigreeFunction    0.0
Age                         0.0
dtype: float64

Готово! Файлы сохранены рядом со скриптом.
```

**Вывод:** получила практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научилась выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.