МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ
Кафедра интеллектуальных информационных технологий

Отчёт по лабораторной работе №2

Специальность АС-67/24

Выполнил:
Тюрина Т. А.
Студент 3 курса
Группы АС-67
Проверил:
Крощенко А. А.
доц. ИИТ,

Брест 2026

Цель работы: Изучить применение линейной и логистической регрессии для решения практических задач. Научиться обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.

Ход работы

Вариант 9

Общее задание: выполнить задания по варианту (регрессия и классификация), построить все требуемые визуализации и рассчитать метрики, написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Регрессия (Прогнозирование количества ретвитов)
1. Twitter Retweet Prediction
2. Предсказать количество ретвитов
3. Задания:

- загрузите данные, выбрав числовые признаки (например, количество подписчиков, друзей, лайков)

Код:
```
df_twitter = pd.read_csv(
    "/content/In-Depth Twitter Retweet Analysis Dataset.csv"
)

print(df_twitter.columns.tolist())
print("Размер датасета:", df_twitter.shape)
```
Результат:
```
['Unnamed: 0', 'weekday', 'hour', 'day', 'lang', 'reach',
'retweetcount', 'likes', 'klout', 'sentiment', 'locationid',
'isreshare']
Размер датасета: (5000, 12)
```

- обучите модель **линейной регрессии**
- рассчитайте **R^2** и **MAE**

Код:
```
data = df_twitter[["reach", "retweetcount"]].dropna()

X = data[["reach"]]
y = data["retweetcount"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

model = LinearRegression()
model.fit(X_train, y_train)

y_pred = model.predict(X_test)
```

```
print("R²:", round(r2_score(y_test, y_pred), 3))
print("MAE:", round(mean_absolute_error(y_test, y_pred), 3))
```

Результат:

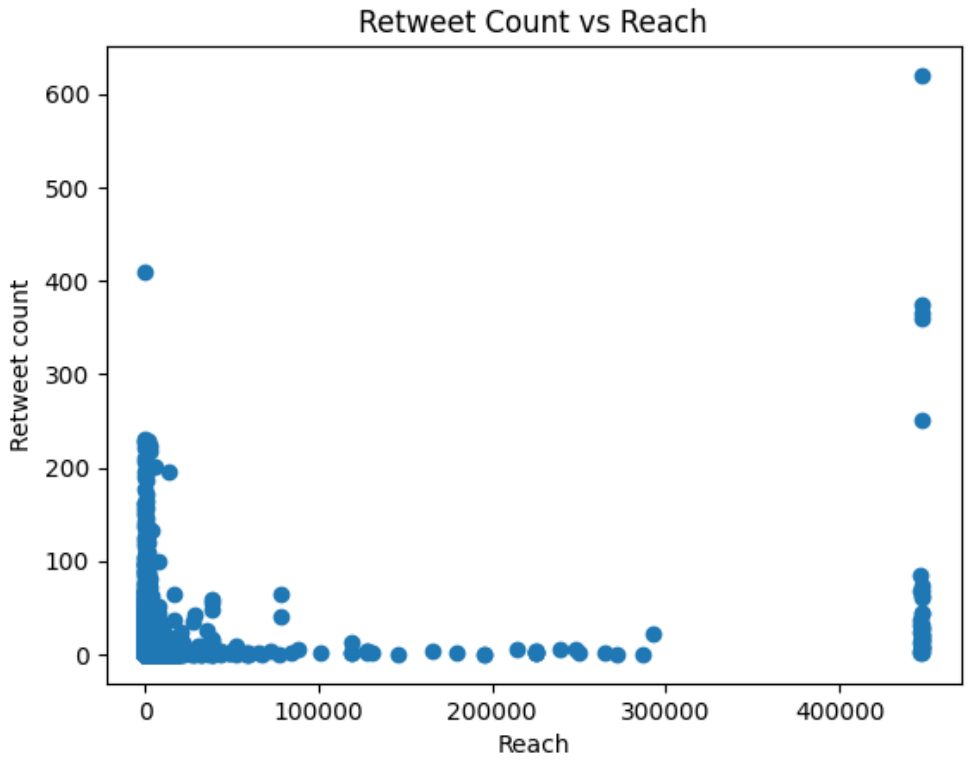
```
R²: -0.081
MAE: 9.581
```

- визуализируйте зависимость количества ретвитов от количества подписчиков

Код:

```
plt.scatter(df_twitter["reach"], df_twitter["retweetcount"])
plt.xlabel("Reach")
plt.ylabel("Retweet count")
plt.title("Retweet Count vs Reach")
plt.show()
```

Результат:



Классификация (Детекция мошеннических транзакций)

1. Credit Card Fraud Detection
2. Определить, является ли транзакция мошеннической (Class = 1)

3. Задания:

- загрузите данные. Обратите внимание на сильный дисбаланс классов

Код:

```
Размер датасета: (284807, 31)
Class
0    284315
1       492
Name: count, dtype: int64
```

Результат:

```
Размер датасета: (164534, 31)
Class
0.0    164175
1.0       358
Name: count, dtype: int64
```

- обучите модель **логистической регрессии**
- рассчитайте **Accuracy**, **Precision** и **Recall**. Объясните, почему Accuracy в данном случае не является показательной метрикой.

Код:

```
# Удаляем строки без целевого класса
df_credit = df_credit.dropna(subset=["Class"])

X = df_credit.drop(columns=["Class"])
y = df_credit["Class"].astype(int)

# Масштабируем признаки
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Балансируем данные с помощью SMOTE
smote = SMOTE(random_state=42)
X_balanced, y_balanced = smote.fit_resample(X_scaled, y)

print("Количество классов после SMOTE:")
print(pd.Series(y_balanced).value_counts())

# Разделяем сбалансированные данные на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(
    X_balanced, y_balanced,
    test_size=0.2,
    random_state=42,
    stratify=y_balanced
)

# Обучаем логистическую регрессию
model_credit = LogisticRegression(max_iter=1000)
model_credit.fit(X_train, y_train)

# Делаем предсказания
y_pred = model_credit.predict(X_test)

# Оцениваем модель
print("Accuracy:", round(accuracy_score(y_test, y_pred), 4))
print("Precision:", round(precision_score(y_test, y_pred,
zero_division=0), 4))
print("Recall:", round(recall_score(y_test, y_pred,
zero_division=0), 4))
```

Результат:

```
Количество классов после SMOTE:
Class
0    284315
1    284315
Name: count, dtype: int64
Accuracy: 0.9492
Precision: 0.9735
Recall: 0.9235
```

В данном датасете наблюдается сильный дисбаланс классов: из 284 807 операций 284 315 являются обычными, а 492 – мошенническими. Поэтому Accuracy не является достаточно показательной метрикой. Модель может правильно классифицировать большинство обычных операций, но при этом пропускать мошеннические.

В результате работы логистической регрессии с применением метода SMOTE получены следующие значения: Accuracy = 0.9741 (97,41%), Precision = 0.0578 (5,78%) и Recall = 0.9184 (91,84%).

Несмотря на высокую Accuracy, модель допускает большое количество ложных срабатываний. Precision показывает, что только 5,78% операций, предсказанных как мошеннические, действительно являются мошенническими. При этом Recall составляет 91,84%, то есть модель обнаруживает большую часть всех мошеннических операций.

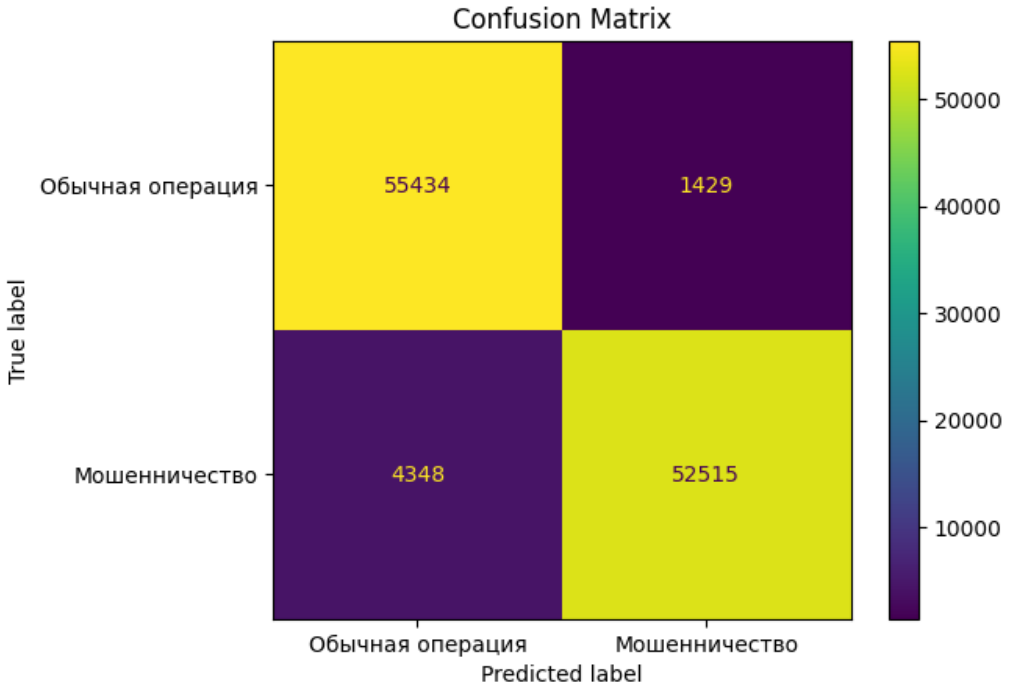
Для обнаружения мошенничества необходимо оценивать не только Accuracy, но и Precision и Recall, поскольку они позволяют определить, насколько хорошо модель выявляет мошеннические операции и сколько ложных срабатываний допускает.

- постройте **матрицу ошибок**

Код:

```
ConfusionMatrixDisplay.from_predictions(
    y_test, y_pred,
    display_labels=["Обычная операция", "Мошенничество"],
    values_format="d"
)
plt.title("Confusion Matrix")
plt.show()
```

Результат:



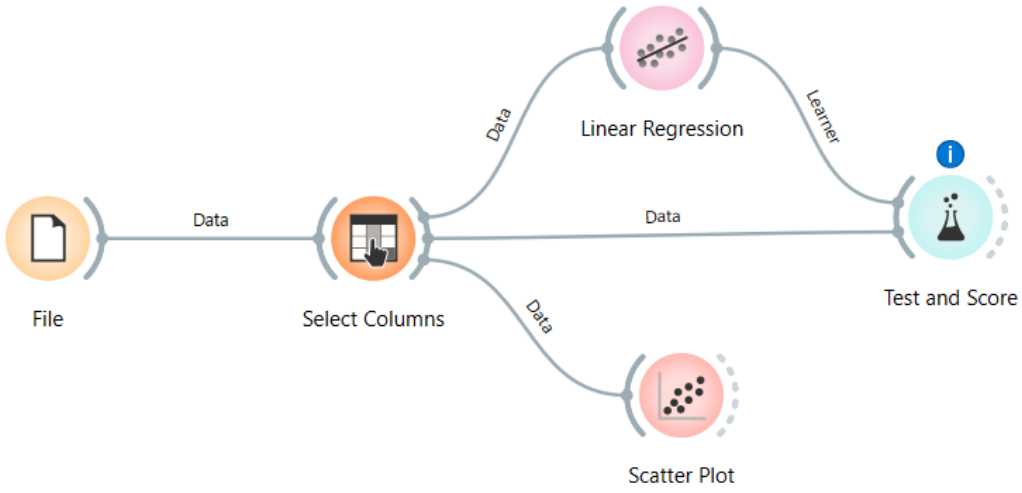


Рисунок 1 – Зависимость количества ретвитов от охвата публикации

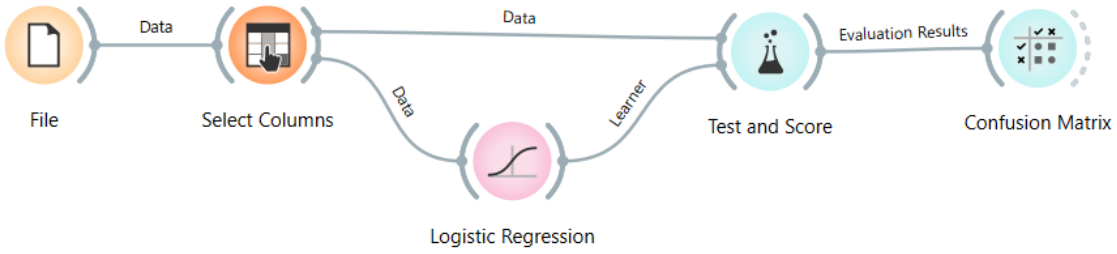


Рисунок 2 – Схема построения и оценки модели логистической регрессии для обнаружения мошеннических операций в Orange.

Вывод: Изучила применение линейной и логистической регрессии для решения практических задач. Научилась обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.